

Thiết Kế Hệ Thống Truy Xuất Và Phân Tích Video Đa Mô Thức Cho Hội Thi Thử Thách Trí Tuệ Nhân Tạo TP.HCM 2026

Phân Tích Thể Lệ, Tiêu Chí Đánh Giá Và Tương Quan Toán Học

Hội thi Thử thách Trí tuệ Nhân tạo Thành phố Hồ Chí Minh năm 2026 (AIC 2026) đặt ra bài toán truy xuất sự kiện nâng cao từ các kho dữ liệu video quy mô lớn¹. Cấu trúc cuộc thi vòng sơ tuyển tập trung vào ba dạng truy vấn với độ phức tạp tăng dần, đòi hỏi sự kết hợp giữa hiểu nội dung thị giác, xử lý ngôn ngữ tự nhiên và căn chỉnh ngữ nghĩa theo thời gian¹.

Phân Loại Dạng Truy Vấn Và Điều Kiện Đáp Án

Dạng truy vấn thứ nhất là Tìm kiếm chính xác theo văn bản (Textual Known Item Search - Textual KIS)¹. Nhiệm vụ yêu cầu định vị một đoạn video và xác định chính xác một khung hình (*frame_id*) nằm trong khoảng thời gian diễn ra sự kiện được mô tả bằng ngôn ngữ tự nhiên¹.

Dạng truy vấn thứ hai là Hỏi - Đáp thị giác (Q&A / Visual Question Answering)¹. Người tham gia không chỉ phải định vị video và khung hình ngữ nghĩa chứa câu trả lời mà còn phải trích xuất câu trả lời chính xác (*answer*) bằng tiếng Việt hoặc tiếng Anh¹.

Dạng truy vấn thứ ba là Truy xuất và căn chỉnh sự kiện video theo thời gian (Temporal Retrieval and Alignment of Key Events - TRAKE)¹. Đây là nhiệm vụ phức hợp đòi hỏi hệ thống phải hiểu cấu trúc ngữ nghĩa dạng chuỗi sự kiện¹. Hệ thống phải tìm ra một video duy nhất khớp nhất với mô tả và xác định chính xác danh sách các khung hình ngữ nghĩa (*semantic keyframes*)

tương ứng với N giai đoạn của chuỗi hành động¹. Đoạn chấp nhận đáp án đúng cho mỗi *semantic keyframe* trong bài toán TRAKE thường rất ngắn, thông thường nhỏ hơn 10 khung hình¹.

Cơ Chế Chấm Điểm Toán Học Và Chiến Lược Tối Ưu Hóa Ranking

Độ chính xác của từng câu trả lời thứ i được định lượng bằng chỉ số Điểm Tương Quan (*R-Score*) nằm trong đoạn $[0, 1]$ ¹. Công thức toán học tính $R\text{-Score}(r_i)$ cho từng dạng truy vấn được quy định như sau:

Đối với truy vấn Textual KIS¹:

$$R\text{-Score}(r_i) = \mathbb{I}(v_i = GT_v \wedge id_i \in [s, e])$$

Trong đó v_i và id_i lần lượt là mã video và mã khung hình dự đoán, GT_v là đáp án video chuẩn, $[s, e]$ là khoảng khung hình đáp án đúng, và $\mathbb{I}(\cdot)$ là hàm chỉ thị nhận giá trị 1 khi điều kiện đúng và 0 khi điều kiện sai¹.
Đối với truy vấn Q&A¹:

$$R\text{-Score}(r_i) = \mathbb{I}(v_i = GT_v \wedge id_i \in [s, e] \wedge a_i = GT_a)$$

Trong đó a_i là câu trả lời văn bản được trích xuất và GT_a là đáp án chuẩn về mặt ngữ nghĩa¹.
Đối với truy vấn TRAKE¹:

$$R\text{-Score}(r_i) = \begin{cases} \frac{1}{N} \sum_{j=1}^N \mathbb{I}(id_{i,j} \in [s_j, e_j]) & \text{nếu } v_i = GT_v \\ 0 & \text{nếu } v_i \neq GT_v \end{cases}$$

Trong đó N là tổng số khoảng khắc ngữ nghĩa trong chuỗi sự kiện, $id_{i,j}$ là khung hình dự đoán cho khoảng khắc thứ j , và $[s_j, e_j]$ là khoảng khung hình chuẩn của khoảng khắc đó¹.

Nếu dự đoán sai video ($v_i \neq GT_v$), điểm $R\text{-Score}$ bằng 0 ngay lập tức¹.

Mỗi đội thi được gửi tối đa 100 câu trả lời cho một truy vấn ($r_1, r_2, \dots, r_{100}$)¹. Điểm Cuối

Cùng (Final Score) cho một truy vấn là trung bình cộng của chỉ số $R@k$ tại 5 ngưỡng xếp hạng $k \in \{1, 5, 20, 50, 100\}$ ¹:

$$R@k = \max_{1 \leq i \leq k} \{R\text{-Score}(r_i)\}$$

$$\text{Final Score} = \frac{1}{5} \sum_{k \in \{1, 5, 20, 50, 100\}} R@k$$

Tương quan toán học của hàm Final Score tạo ra tác động lớn đến thiết kế hệ thống xếp hạng:

Vị trí đầu	R@1	R@5	R@20	R@50	R@100	Final
------------	-----	-----	------	------	-------	-------

tiên có đáp án chính xác (R-Score =1.0)						Score Tương Ứng
Xếp hạng 1 (r_1)	1.0	1.0	1.0	1.0	1.0	1.00
Xếp hạng 2 đến 5 ($r_2 \dots r_5$)	0.0	1.0	1.0	1.0	1.0	0.80
Xếp hạng 6 đến 20 ($r_6 \dots r_{20}$)	0.0	0.0	1.0	1.0	1.0	0.60
Xếp hạng 21 đến 50 ($r_{21} \dots r_{50}$)	0.0	0.0	0.0	1.0	1.0	0.40
Xếp hạng 51 đến 100 ($r_{51} \dots r_{100}$)	0.0	0.0	0.0	0.0	1.0	0.20

Mô hình toán học trên cho thấy việc đưa đáp án đúng vào vị trí Top-1 đóng góp đến 20% tổng điểm của truy vấn đó ($R@1$ xuất hiện duy nhất ở vị trí đầu nhưng ảnh hưởng lên toàn bộ các ngưỡng $R@k$ sau đó)¹. Do đó, chiến lược xếp hạng của hệ thống phải đạt độ chính xác cao ở vị trí ưu tiên số 1, đồng thời duy trì sự đa dạng mô hình (*diversity*) ở các vị trí từ 2 đến 100 nhằm bao phủ rủi ro khi độ tin cậy của mô hình xếp hạng đầu không đạt tuyệt đối³.

Đánh Giá Nguồn Dữ Liệu Ban Đầu Và Yêu Cầu Nâng Cấp

Dữ liệu sơ tuyến được cung cấp gồm tập tin video thô, ảnh khung hình tĩnh (*Keyframes*), kết quả phát hiện vật thể dạng JSON từ mô hình Faster R-CNN (pretrained trên OpenImages V4), vector đặc trưng CLIP (trích xuất bằng clip-ViT-B-32 lưu trữ trong tập tin .npy), và tệp *Metadata* thông tin từ YouTube¹.

Các đặc trưng được cung cấp sẵn chỉ mang tính chất minh họa và baseline¹. Mô hình clip-ViT-B-32 có độ phân giải thấp và không gian biểu diễn hạn chế, dễ dẫn đến hiện tượng bỏ sót thông tin chi tiết hoặc nhầm lẫn ngữ nghĩa không gian-thời gian³. Tương tự, kết quả nhận diện vật thể từ Faster R-CNN OpenImages V4 thiếu khả năng nhận diện các khái niệm hành động và quan hệ ngữ cảnh phức tạp³. Vì vậy, để xây dựng một hệ thống tối ưu đáp ứng tiêu chí AIC 2026, việc tự trích xuất lại các đặc trưng bằng các mô hình nền tảng (*Foundation Models*) tiên tiến là điều bắt buộc³.

Giải Pháp Kỹ Thuật Và Mô Hình Hóa Cho Từng Dạng Truy Vấn

Xử Lý Truy Vấn Textual KIS Bằng Bi-Encoder Đa Tầng Và Cross-Encoder Reranking

Đối với dạng truy vấn Textual KIS, mục tiêu là tìm chính xác đoạn video và khung hình dựa trên mô tả văn bản¹. Mô hình kiến trúc tối ưu vận hành theo cơ chế hai giai đoạn bao gồm truy xuất diện rộng và tái xếp hạng chuyên sâu⁴. Giai đoạn truy xuất diện rộng ứng dụng chiến lược biểu diễn vector kép kết hợp giữa CLIP và SigLIP2³. Trong cấu trúc này, CLIP chịu trách nhiệm nắm bắt ngữ cảnh khái niệm tổng thể, trong khi SigLIP2 tối ưu hóa khả năng nhận diện các chi tiết tĩnh ở cấp độ hạt mịn³. Nhằm tăng cường năng lực biểu diễn chuỗi hành động theo thời gian, các vector khung hình tĩnh được bổ sung đặc trưng từ mô hình nền tảng InternVideo2⁶. Nhờ quy trình tiền huấn luyện phân giải không-thời gian đa tầng, InternVideo2 giúp mô hình hóa vượt trội các biến đổi hành động liên tục⁶. Kết quả tìm kiếm từ các không gian vector độc lập sau đó được dung hợp thông qua thuật toán Dung hợp Xếp hạng Tương hỗ (Reciprocal Rank Fusion - RRF)³. Ở giai đoạn tái xếp hạng tinh vi, hệ thống trích xuất danh sách các ứng viên hàng

đầu từ bước truy xuất thô và đưa qua một mô hình Cross-Encoder đa mô thức hoặc mô hình Ngôn ngữ Thị giác (Vision-Language Model - VLM) để tính toán điểm tương quan trực tiếp giữa văn bản truy vấn và hình ảnh thực tế, giúp tối ưu chỉ số $R@1$ ⁴.

Xử Lý Truy Vấn Q&A Bằng Kiến Trúc Video-RAG Và VLM Căn Chỉnh

Bài toán Q&A yêu cầu trích xuất đồng thời vị trí không gian-thời gian và câu trả lời ngữ nghĩa chính xác¹. Hệ thống được xây dựng dựa trên đường ống Thể hệ Truy xuất Tăng cường cho Video (Video Retrieval-Augmented Generation - Video-RAG) tích hợp đa nguồn dữ liệu¹¹. Quá trình xử lý bắt đầu bằng việc sử dụng mô tả sự kiện để truy xuất Top-K đoạn video ứng viên thông qua các mô hình nhúng dense vector¹¹. Đồng thời, hệ thống thực hiện trích xuất toàn bộ bản ghi âm thanh thành văn bản (*Speech – to – Text*) bằng mô hình Whisper Large-v3, kết hợp với công nghệ nhận dạng chữ viết trên màn hình (*OCR*) bằng PaddleOCR để lưu trữ vào chỉ mục văn bản thưa BM25³.

Khi thực hiện suy luận đa mô thức, các khung hình thuộc video ứng viên cùng với câu hỏi, văn bản thuyết minh và kết quả OCR được đưa đồng thời vào mô hình VLM thể hệ mới như Qwen2-VL hoặc LLaVA-Video⁵. Mô hình Qwen2-VL ứng dụng cơ chế Naive Dynamic Resolution cho phép xử lý khung hình ở nhiều tỷ lệ phân giải mà không làm méo hình ảnh, kết hợp với cơ chế Multimodal Rotary Position Embedding (M-RoPE) giúp căn chỉnh vị trí thời gian của video chính xác⁵. Cuối cùng, VLM tạo ra câu trả lời văn bản ngắn gọn (GT_a) đồng thời chỉ định vị trí

thời gian chứa bằng chứng thị giác, trong đó $frame_id$ ứng với khung hình có trọng số chú ý cao nhất đối với từ khóa đáp án sẽ được lựa chọn để nộp bài¹.

Xử Lý Truy Vấn TRAKE Bằng Thuật Toán Tái Xếp Hạng Chuỗi Thời Gian

Nhiệm vụ TRAKE đòi hỏi hệ thống phải duy trì tính nhất quán về mặt thứ tự thời gian của N khoảng khắc ngữ nghĩa ($id_{i,1} < id_{i,2} < \dots < id_{i,N}$)¹. Phương pháp giải quyết cốt lõi dựa trên thuật toán phân rã truy vấn và tìm kiếm căn chỉnh đa chặng³.

Giả sử câu hỏi TRAKE mô tả một chuỗi hành động gồm N bước $E_1, E_2, \dots, E_N$ (như Chạy đà $\rightarrow$ Giậm nhảy $\rightarrow$ Bay qua xà $\rightarrow$ Tiếp đất)¹. Ban đầu, hệ thống thực hiện N lượt tìm kiếm độc lập tương ứng với các mô tả $Q_{E_1}, Q_{E_2}, \dots, Q_{E_N}$ trên toàn bộ kho keyframe để thu được các danh sách kết quả xếp hạng $R_1, R_2, \dots, R_N$ ³. Sau đó, hệ thống tiến hành lọc các video xuất hiện đồng thời trong cả N danh sách ứng viên³. Với mỗi video chung v_k , hệ thống tìm kiếm bộ khung hình ($id_{k,1}, id_{k,2}, \dots, id_{k,N}$) thỏa mãn điều kiện ràng buộc thứ tự thời gian nghiêm ngặt¹:

$$id_{k,1} < id_{k,2} < \dots < id_{k,N}$$

Điểm số tích hợp $S_{final}(v_k)$ của video v_k được tính toán bằng tổng điểm truy xuất thành phần kết hợp với phạt khoảng cách thời gian không hợp lý nếu khoảng cách giữa các khung hình vi phạm quy luật vận động tự nhiên³:

$$S_{final}(v_k) = \sum_{j=1}^N \text{Score}(Q_{E_j}, id_{k,j}) - \lambda \cdot \Phi(id_{k,1}, \dots, id_{k,N})$$

Trong đó $\text{Score}(Q_{E_j}, id_{k,j})$ là điểm tương đồng giữa mô tả sự kiện j và khung hình $id_{k,j}$, $\Phi(\cdot)$ là hàm phạt vi phạm khoảng cách thời gian, và λ là hệ số điều chỉnh³. Sau khi xác định được video v_i có điểm S_{final} cao nhất, các vị trí $id_{i,j}$ được tinh chỉnh chi tiết trong phạm vi cửa sổ lân cận bằng mô hình phân đoạn hành động hoặc kiểm tra sự kiện ngữ nghĩa thông qua kỹ thuật ghép bảng ảnh (*FramePaneling*) đưa vào VLM để đảm bảo khung hình nộ rơi chính xác vào khoảng đáp án ngắn (< 10 khung hình) của ban tổ chức¹.

Kiến Trúc Hệ Thống Chuẩn SOTA Đáp Ứng Tiêu Chí Đánh Giá

Kiến trúc hệ thống tổng thể được thiết kế theo mô-đun hóa cao, phân chia rõ ràng giữa luồng xử lý dữ liệu ngoại tuyến và luồng xử lý truy vấn thời gian thực³.

Quy Trình Xử Lý Dữ Liệu Ngoại Tuyến Và Luồng Truy Vấn Thời Gian Thực

Trong luồng xử lý dữ liệu ngoại tuyến, hệ thống thực hiện trích xuất khung hình linh hoạt dựa trên biến thiên hiệu số nội dung (Scene Cut Detection) nhằm bắt trọn các khoảnh khắc chuyển cảnh ngữ nghĩa thay vì phụ thuộc vào I-Frame nén¹. Tiếp theo, hệ thống trích xuất song song nhiều lớp đặc trưng: CLIP-ViT-L/14 và SigLIP2-so400m mã hóa đặc trưng tĩnh, InternVideo2-1B mã hóa chuỗi khung hình liên tiếp, YOLOv8x hoặc DINOv2 kết hợp Grounding DINO gán nhãn đối tượng chi tiết, trong khi PaddleOCR và Whisper-Large-v3 chuyển đổi chữ viết và âm thanh thành dữ liệu văn bản³. Toàn bộ dữ liệu này được đưa vào cơ sở dữ liệu vector (Qdrant hoặc Milvus) sử dụng chỉ mục HNSW cho dense vector và cơ sở dữ liệu tìm kiếm văn bản (Elasticsearch) sử dụng chỉ mục BM25¹⁰.

Trong luồng xử lý truy vấn thời gian thực, khi nhận truy vấn từ ban giám khảo, bộ phân tích truy vấn (*QueryParser*) sẽ phân rã văn bản thành các cụm từ khóa, câu hỏi hoặc chuỗi sự kiện

thời gian. Truy vấn sau đó được chuyển đến lớp truy xuất hỗn hợp (*HybridRetrievalLayer*), vận hành song song tìm kiếm dense vector trên cơ sở dữ liệu Qdrant và tìm kiếm sparse text trên Elasticsearch³. Kết quả tìm kiếm được hợp nhất bằng thuật toán RRF³. Đối với truy vấn TRAKE, công cụ kiểm soát ràng buộc thời gian (*TemporalAlignmentEngine*) thực hiện lọc và sắp xếp chuỗi khung hình thỏa mãn điều kiện $id_1 < id_2 < \dots < id_N$ ¹. Cuối cùng, mô hình VLM (Qwen2-VL hoặc LLaVA-Video) đóng vai trò tái xếp hạng chuyên sâu và trích xuất đáp án cho bài toán Q&A, trước khi bộ tối ưu danh sách nộp bài (*SubmissionRankOptimizer*) cấu trúc lại Top-100 kết quả để đạt điểm số Final Score cao nhất¹.

Bảng Mô-đun Hệ Thống Và Nhiệm Vụ Kỹ Thuật

Mô-đun Hệ Thống	Mô Hình / Công Nghệ Cốt Lõi	Đầu Ra Triển Khai	Đáp Ứng Dạng Truy Vấn
Ingestion & Feature Extractor	SigLIP2, InternVideo2, Whisper-v3, PaddleOCR	Vectors (.npy), JSON metadata bổ sung	Tất cả dạng truy vấn ¹
Hybrid Vector Indexer	Qdrant / Milvus (HNSW Index), Elasticsearch	Hệ thống tra cứu vector & text thời gian thực	Textual KIS, Q&A ¹⁰
Temporal Alignment Engine	Dynamic Programming, Algorithm RRF Multi-Stage	Chuỗi khung hình khớp thứ tự thời gian	TRAKE ¹
VLM Answer Extractor	Qwen2-VL-72B / LLaVA-Video-7B	Văn bản đáp án (a_i) & Vị trí frame (id_i)	Q&A, Refine Top-1 KIS ¹
Rank Optimization Engine	Diversity Re-ranking, Rocchio Feedback	Bảng 100 kết quả nộp chuẩn định dạng AIC	Tất cả dạng truy vấn ¹

Nguồn Tài Liệu Bổ Sung Và Nguồn Lực Đào Tạo Mô

Hình

Để thiết kế hệ thống đạt điểm số cao nhất, việc kế thừa các nghiên cứu Open-Source hàng đầu và sử dụng các tập dữ liệu huấn luyện công khai đóng vai trò then chốt¹⁷.

Bảng So Sánh Các Mô Hình Nền Tảng Đa Mô Thức SOTA (2024–2026)

Tên Mô Hình	Loại Mô Hình	Điểm Mạnh Cốt Lõi	Hạn Chế / Chi Phí Tính Toán	Ứng Dụng Tối Ưu Trong AIC
InternVideo2	Video Foundation Model (ViFM)	Tiếp nhận thông tin không-thời gian xuất sắc, dẫn đầu các bảng xếp hạng video retrieval ⁶ .	Cần tài nguyên GPU lớn (A100/H100) khi trích xuất ⁶ .	Trích xuất vector dense cho Textual KIS & TRAKE ⁶ .
Qwen2-VL / Qwen2.5-VL	Vision-Language Model (VLM)	Hỗ trợ Naive Dynamic Resolution, M-RoPE, trích xuất OCR và đọc video dài rất mạnh ⁵ .	Tốc độ suy luận chậm hơn so with mô hình Bi-Encoder ⁴ .	Mô hình suy luận chính cho bài toán Q&A ⁵ .
SigLIP2	Dense Vision-Text Encoder	Độ chính xác khớp từ khóa-hình ảnh tĩnh ở mức chi tiết cực cao ³ .	Không tự nhiên mã hóa được thông tin chuỗi động theo thời gian ³ .	Truy xuất nhanh giai đoạn 1 cho Textual KIS kết hợp với CLIP ³ .
LLaVA-Video / LLaVA-OV	Video LLM / Frame Paneling	Hỗ trợ kỹ thuật Paneled Images giúp nâng cao năng lực đọc video dài không cần finetune ¹⁵ .	Tốn bộ nhớ VRAM khi xử lý số lượng khung hình lớn cùng lúc ¹² .	Tái xếp hạng các video phức tạp và xác định keyframe câu trả lời ¹⁵ .

Kho Mã Nguồn Mở Và Nguồn Dữ Liệu Thực Nghiệm

Nghiên cứu kiến trúc hệ thống Vortex – mô hình đạt thành tích cao tại AIC 2025 – cung cấp giải pháp thực tiễn về việc kết hợp nhúng kép CLIP và SigLIP2 qua RRF, tích hợp thuật toán tìm kiếm thời gian đa chặng và phản hồi vòng lặp Rocchio³. Bên cạnh đó, khung làm việc MAVEN minh họa hiệu quả của mạng lưới đa tác tử trong việc dung hợp tín hiệu OCR, đối tượng và màu sắc cho truy xuất sự kiện². Việc tham chiếu kho mã nguồn chính thức của InternVideo2 và Qwen2-VL giúp tối ưu hóa quy trình trích xuất đặc trưng và suy luận VLM trên hạ tầng GPU local⁵.

Về dữ liệu huấn luyện và đánh giá, các tập dữ liệu quy mô lớn như InternVid và WebVid-10M cung cấp hàng triệu cặp video-văn bản chất lượng cao để tinh chỉnh không gian nhúng⁶. Để đánh giá năng lực của VLM đối với truy vấn Q&A và video dài, các bộ benchmark như Video-MME, LongVideoBench và MLVU là tiêu chuẩn thực nghiệm phù hợp⁵. Ngoài ra, các tập dữ liệu ActivityNet Captions và Charades-STA hỗ trợ huấn luyện mô hình dự đoán ranh giới khoảnh khắc cho tác vụ TRAKE⁹.

Kết Luận Và Lộ Trình Triển Khai Nâng Cao

Để đáp ứng chính xác tiêu chí đánh giá của AIC 2026 và tối đa hóa chỉ số Final Score, chiến lược thiết kế dự án cần tập trung vào ba định hướng cốt lõi¹.

Trước hết, việc nâng cấp hạ tầng đặc trưng ngoại tuyến là bước đi bắt buộc¹. Hệ thống không nên phụ thuộc vào đặc trưng clip-ViT-B-32 hay kết quả Faster R-CNN mặc định mà cần chủ động trích xuất lại các lớp vector chất lượng cao sử dụng SigLIP2, InternVideo2, kết hợp với Whisper-v3 cho âm thanh và PaddleOCR cho chữ xuất hiện trên màn hình¹.

Tiếp theo, việc làm chủ thuật toán căn chỉnh thời gian là chìa khóa để giải quyết triệt để truy vấn TRAKE¹. Phương pháp phân rã câu hỏi thành chuỗi sự kiện kết hợp kiểm tra điều kiện ràng buộc

chỉ số khung hình ($id_1 < id_2 < \dots < id_N$) cho phép hệ thống định vị chính xác các khoảng khung hình đáp án ngắn từ ban tổ chức¹.

Cuối cùng, chiến lược tạo danh sách 100 câu trả lời nộp bài phải tuân thủ chặt chẽ mô hình toán

học của hàm Final Score¹. Vị trí xếp hạng 1 (r_1) cần được ưu tiên xử lý bởi các mô hình

Cross-Encoder hoặc VLM mạnh nhất để đảm bảo chỉ số $R@1$ đạt điểm tối đa, trong khi các vị

trí từ r_2 đến r_{100} cần đa dạng hóa các ứng viên từ nhiều không gian vector khác nhau nhằm

duy trì độ bao phủ tối ưu cho các ngưỡng $R@5, R@20, R@50, R@100$ ¹.

Nguồn trích dẫn

1. Thông-tin-vong-So-tuyen-AIC2026.pdf
2. Program for Saturday, December 14th, 2024 - EasyChair, <https://easychair.org/smart-program/SOICT2024/2024-12-14.html>
3. Vortex: Multi-Modal Fusion System for Intelligent Video Retrieval - arXiv, <https://arxiv.org/html/2606.19682v1>
4. Introducing the Ettin Reranker Family - Hugging Face,

- <https://huggingface.co/blog/ettin-reranker>
5. Qwen2-VL: Enhancing Vision-Language Model's Perception of the World at Any Resolution, <https://arxiv.org/html/2409.12191v1>
 6. InternVideo2: Scaling Foundation Models for Multimodal Video Understanding - arXiv, <https://arxiv.org/html/2403.15377v3>
 7. Reranking - Tools in Data Science, <https://tds.s-anand.net/2026-02/docs/week-4/reranking/>
 8. InternVideo2: Scaling Video Foundation Models for Multimodal Video Understanding - arXiv, <https://arxiv.org/html/2403.15377v1>
 9. ViLL-E: Video LLM Embeddings for Retrieval - arXiv, <https://arxiv.org/html/2604.12148v1>
 10. Semantic Search Implementation: A Practical Engineering Guide - Atlan, <https://atlan.com/know/ai-agent/data-for-ai/semantic-search-implementation/>
 11. Open-Ended and Knowledge-Intensive Video Question Answering - arXiv, <https://arxiv.org/pdf/2502.11747>
 12. Towards Effective and Efficient Long Video Understanding of Multimodal Large Language Models via One-shot Clip Retrieval - arXiv, <https://arxiv.org/html/2512.08410v1>
 13. video-retrieval · GitHub Topics, <https://github.com/topics/video-retrieval?o=asc&s=stars>
 14. Build OpenClaw RAG Pipeline: Step-by-Step Guide | Fastio, <https://fast.io/resources/openclaw-rag-pipeline/>
 15. Video Panels for Long Video Understanding - CVF Open Access, https://openaccess.thecvf.com/content/CVPR2026/papers/Doorenbos_Video_Panels_for_Long_Video_Understanding_CVPR_2026_paper.pdf
 16. Video Panels for Long Video Understanding - arXiv, <https://arxiv.org/html/2509.23724v1>
 17. GitHub - zyayoung/Awesome-Video-LLMs: Explore VLM-Eval, a framework for evaluating Video Large Language Models, enhancing your video analysis with cutting-edge AI technology., <https://github.com/zyayoung/Awesome-Video-LLMs>
 18. Video-Language Understanding: A Survey from Model Architecture, Model Training, and Data Perspectives - GitHub, <https://github.com/nguyentthong/video-language-understanding>
 19. Query-aware Frame Selection and Multi-Resolution Adaptation for Video-LLMs - arXiv, <https://arxiv.org/html/2506.22139v3>
 20. video-grounding · GitHub Topics, <https://github.com/topics/video-grounding>